



西安交通大学  
XI'AN JIAOTONG UNIVERSITY

# 第五讲： 如何让程序更快？

师斌

School of Computer Science & Technology



# >> 如何让计算机更快?

## ➤ 概念

- The **clock speed** (时钟速度) measures the number of cycles your CPU executes per second, measured in GHz (gigahertz)
- 时钟周期 (cycles) 是CPU工作的**最短时间单位**

## ➤ 性能公式

$$\frac{\text{time}}{\text{program}} = \frac{\text{time}}{\text{cycle}} \times \frac{\text{cycles}}{\text{instruction}} \times \frac{\text{instructions}}{\text{program}}$$

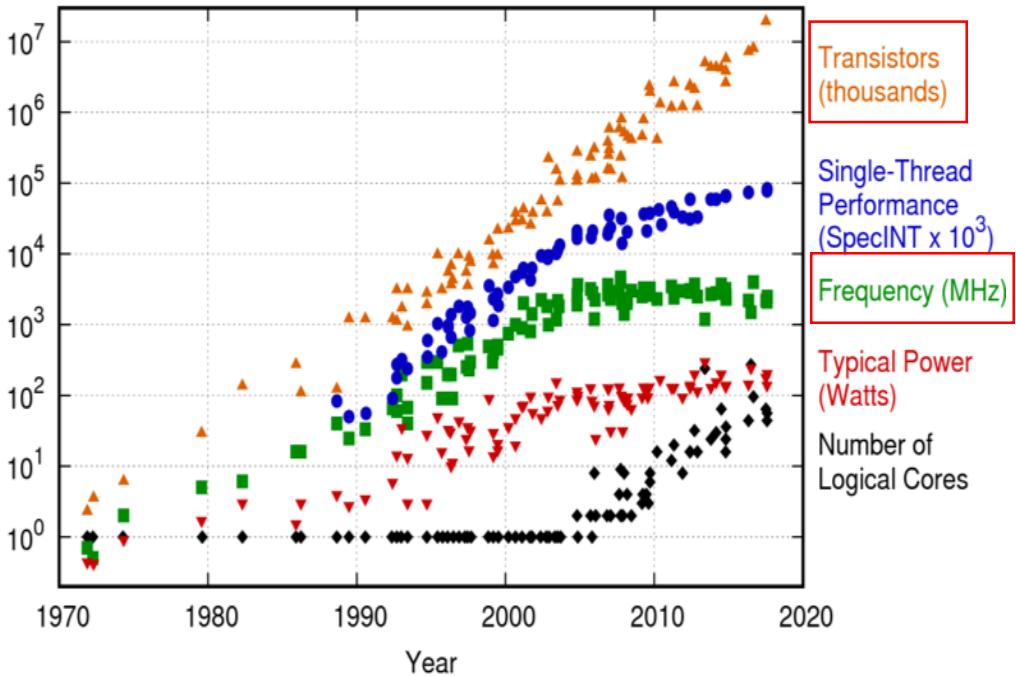
一个时钟  
周期为多  
长时间?

在每条指令上  
花费多少个时  
钟周期?

执行一项任  
务需要多  
少条指令?

# » 途径1：加速时钟周期

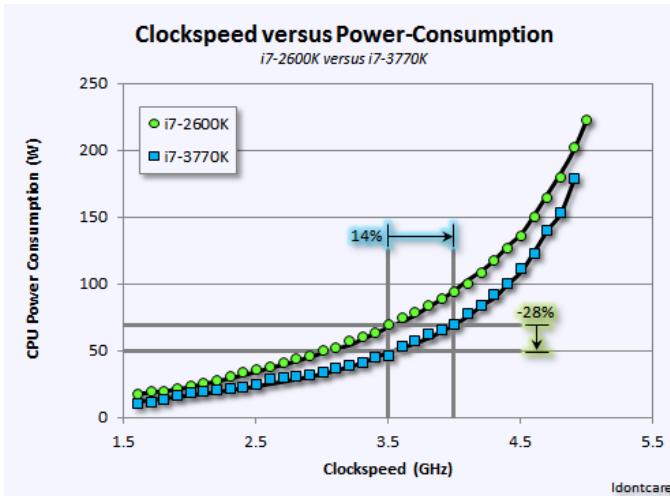
42 Years of Microprocessor Trend Data



芯片发展趋势数据

为什么过去 10 年 CPU 时钟速度  
没有明显提高？

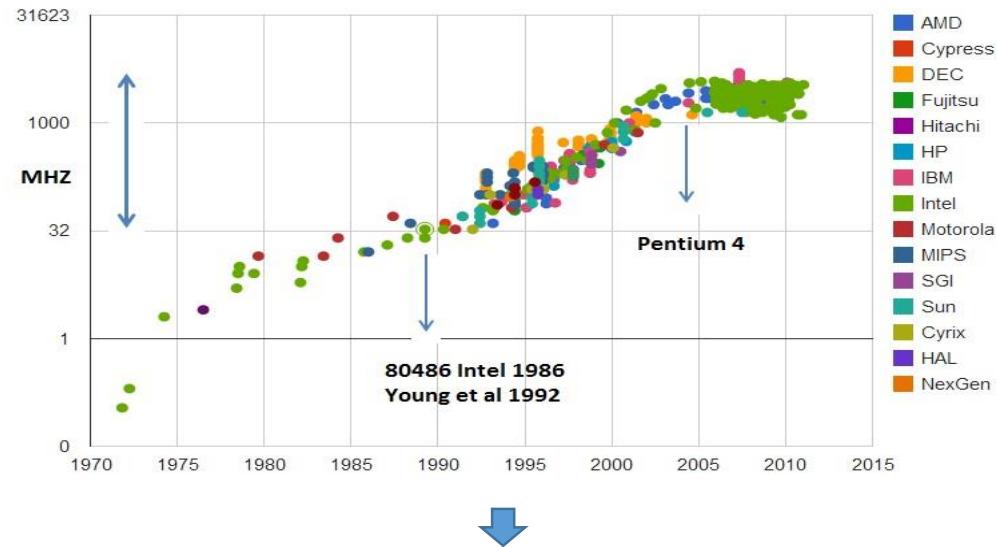
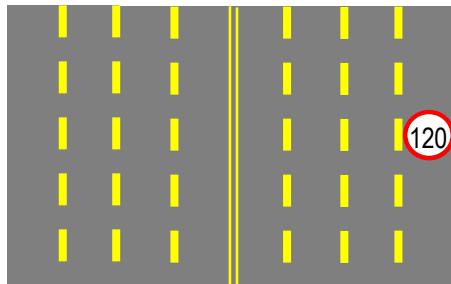
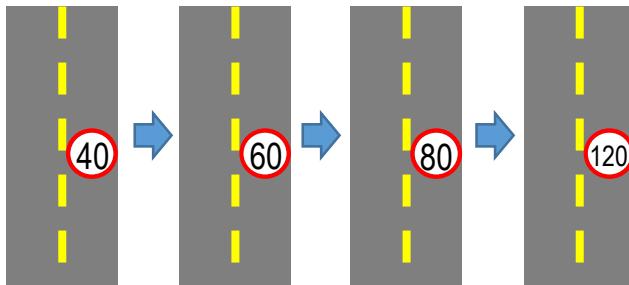
能耗：



对于处理器来讲，纯高频率的设计  
在能耗方面并不合理：

- 我们打开和关闭晶体管的速度越快，  
产生的热量就越多。
- 时钟速度的增加意味着电压的增加，  
并且这与功率之间存在三次依赖性。

# » 途径2：减少每条指令平均花费的时钟周期数CPI



## Instruction-level parallelism

for executing more than one basic instruction one time.

## Task-level parallelism

for distributing tasks across different processors.

## Data parallelism

for distributing the data across different processors.

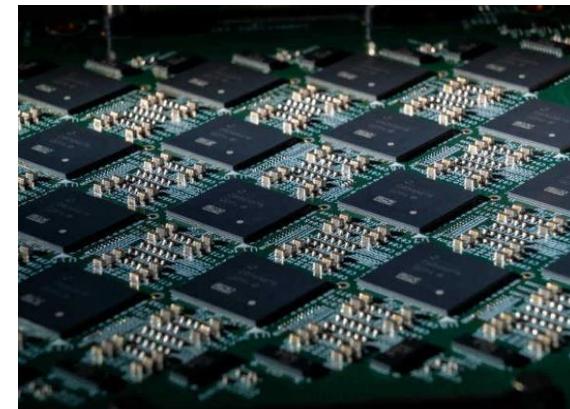
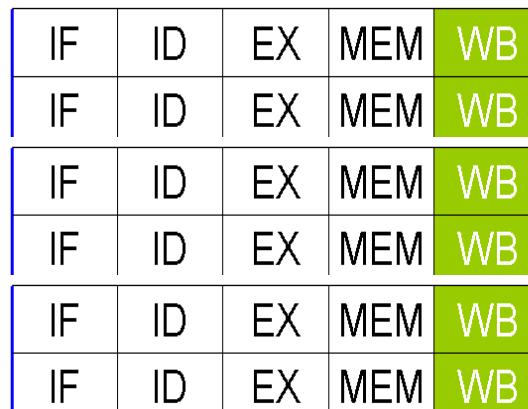
# » 途径2：减少每条指令平均花费的时钟周期数CPI

## ● 途径2-1：Instruction-Level Parallelism

$$\text{Average ILP} = \frac{\text{instructions}}{\text{cycles}}$$

Instr. No.	Pipeline Stage						
1	IF	ID	EX	MEM	WB		
2		IF	ID	EX	MEM	WB	
3			IF	ID	EX	MEM	WB
4				IF	ID	EX	MEM
5					IF	ID	EX
Clock Cycle	1	2	3	4	5	6	7

RISC机器的五层流水线示意图 (IF: 读取指令, ID: 指令解码, EX: 运行, MEM: 存储器访问, WB: 写回寄存器)



1. 流水线

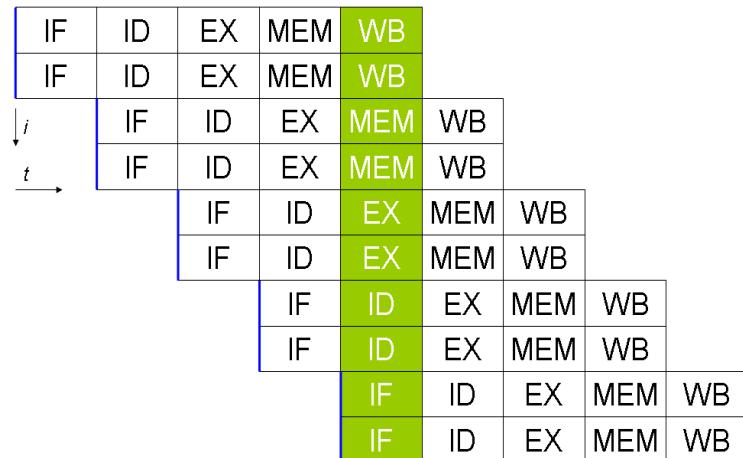
2. 超标量

3. 多核多CPU

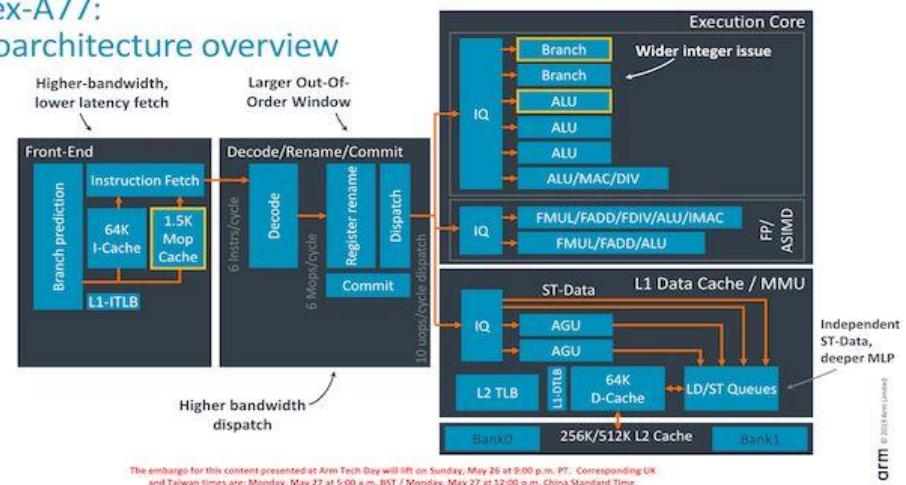
# » 途径2：减少每条指令平均花费的时钟周期数CPI

## 途径2-1：Instruction-level parallelism

$$\text{Average ILP} = \frac{\text{instructions}}{\text{cycles}}$$



Cortex-A77:  
Microarchitecture overview



超标量流水线理想时空图

现代计算机

15级流水线，4条指令同时发射，最多60条指令并行，提速60倍

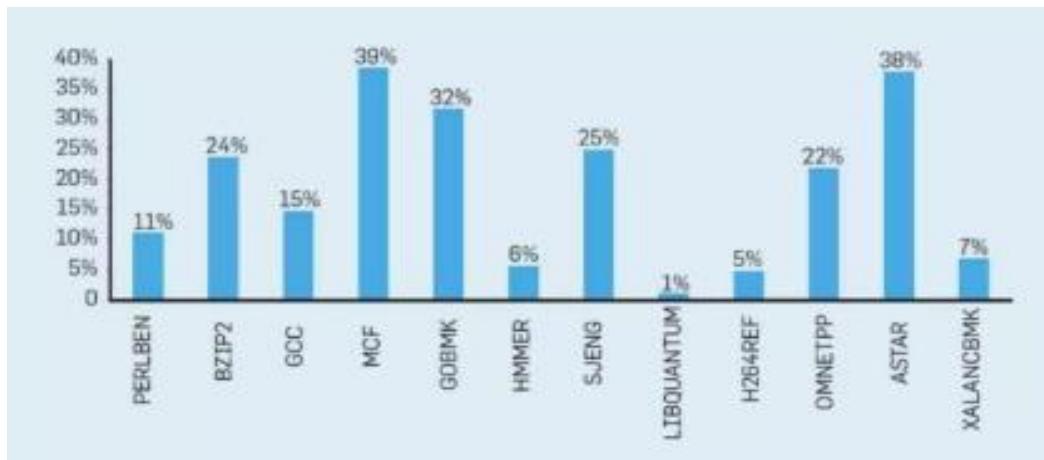
# >> 如何让计算机更快?

➤ 流水线的思路是否有局限性?

➤ 有! 不知道下一条指令时, 无法装载流水线。

➤ 例如: 条件判断语句下一条指令

➤ 于是, 预测下一条指令。



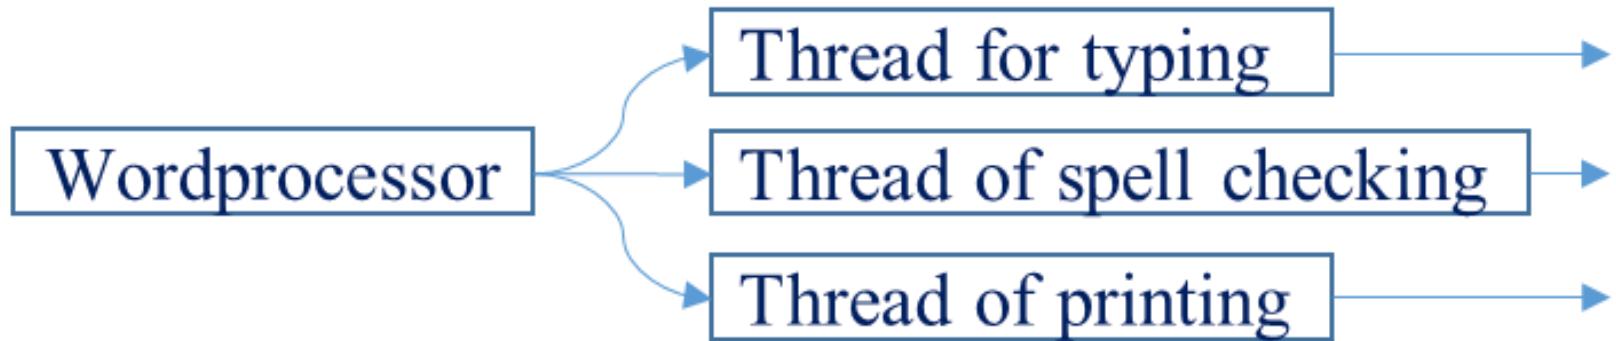
分支预测错误率

- 75% 的分支指令预测对了正常执行, 预测错误则流水线预取作废。
- 最先进的分支预测技术, 平均有20% 的预测错误。

# » 途径2：减少每条指令平均花费的时钟周期数CPI

## 途径2-2：Task-level parallelism

$$\text{Average ILP} = \frac{\text{instructions}}{\text{cycles}}$$



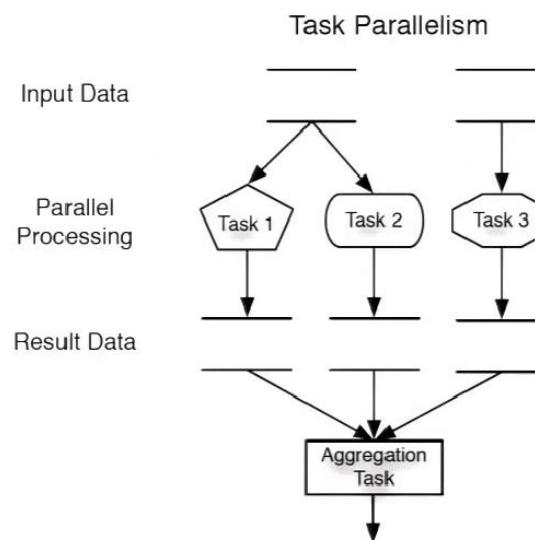
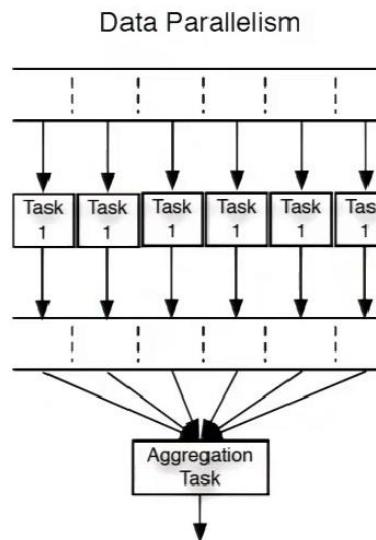
思路：将任务分解成多线程，需要将任务分解成若干子任务。

# » 途径2：减少每条指令平均花费的时钟周期数CPI

## 途径2-3：Data parallelism

$$\text{Average ILP} = \frac{\text{instructions}}{\text{cycles}}$$

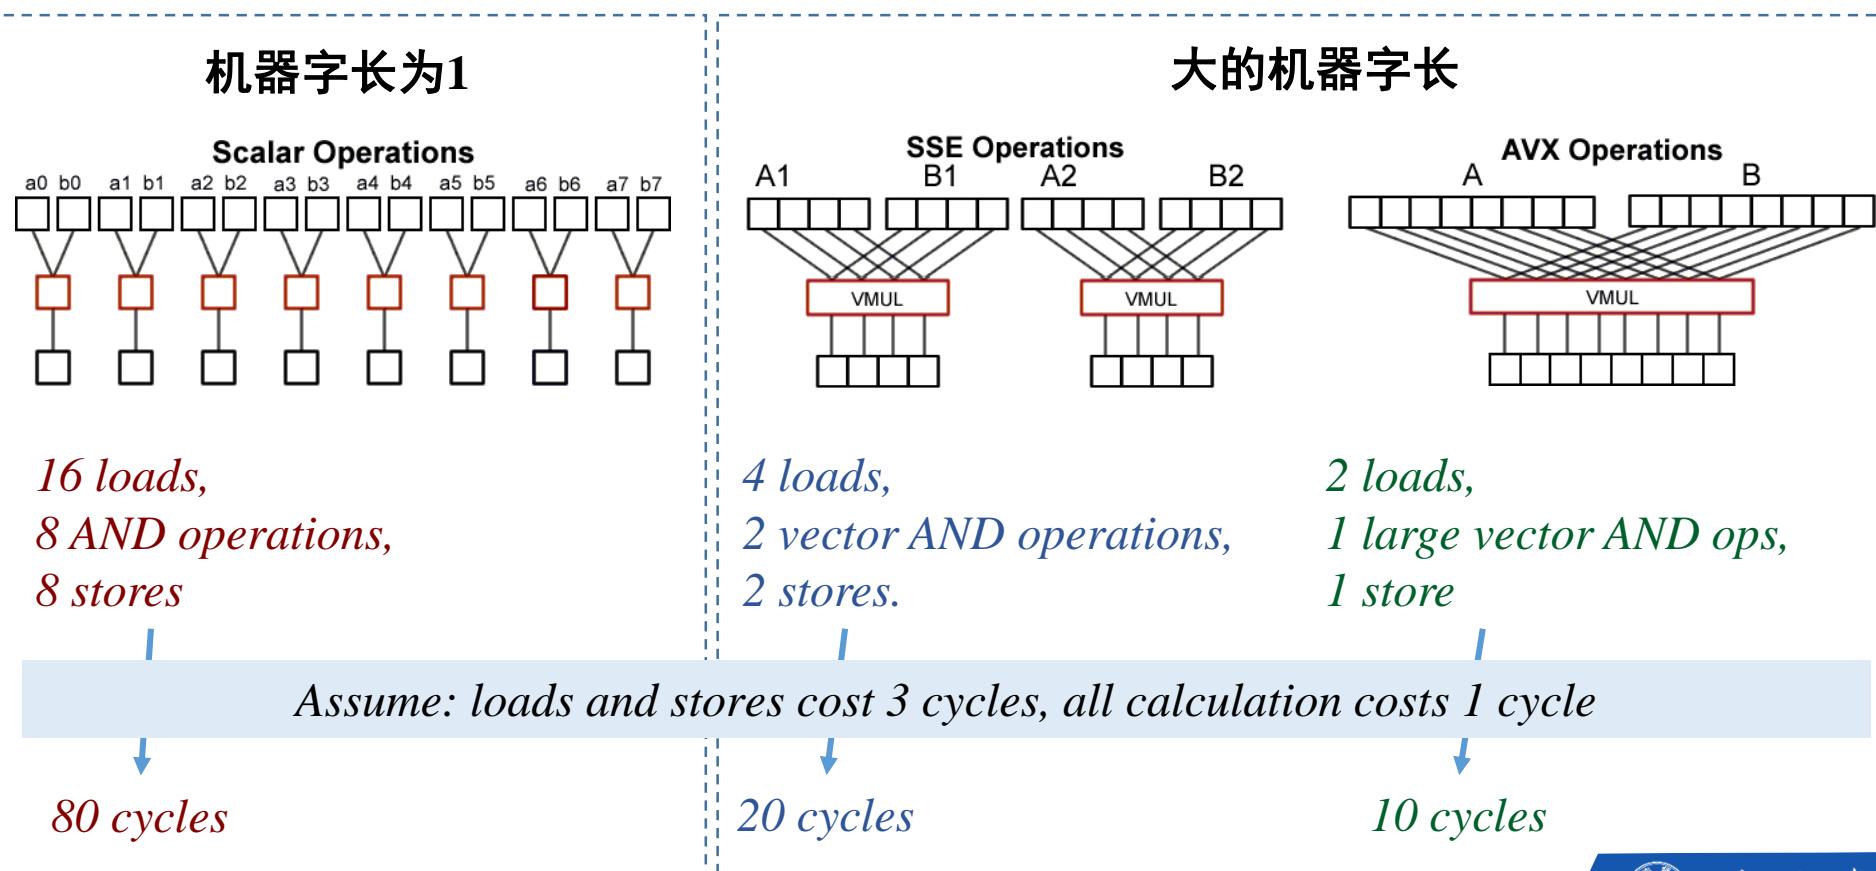
将要处理的数据分配到不同处理器上



# » 途径2：减少每条指令平均花费的时钟周期数CPI

## 途径2-4：机器字长的变化：

- 寄存器可以存储一组单一数据类型的数据元素。
- 计算过程可以同时处理多个数据元素



# >> 如何让计算机更快?

- 并行的思路是否有局限性?
  - 还有! 不是所有的程序都能并行

**Code1: ILP = 1**

- i.e. must execute serially

**Code2: ILP = 3**

- i.e. can execute at the same time

code1:     $r1 \leftarrow r2 + 1$   
             $r3 \leftarrow r1 / 17$   
             $r4 \leftarrow r0 - r3$

code2:     $r1 \leftarrow r2 + 1$   
             $r3 \leftarrow r9 / 17$   
             $r4 \leftarrow r0 - r10$

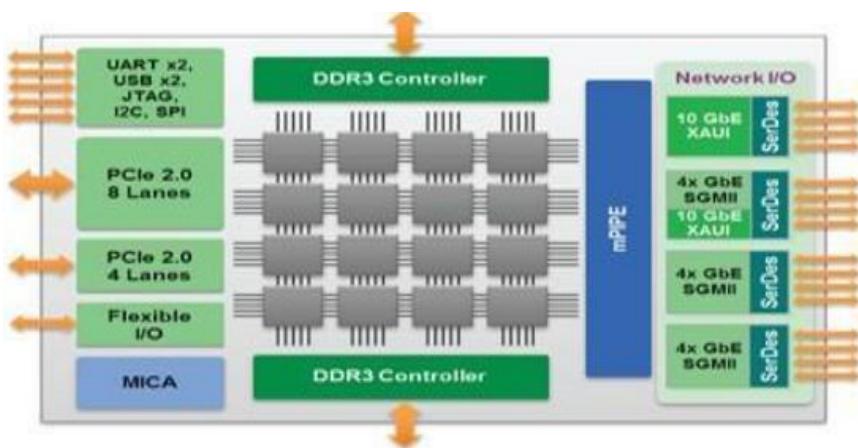
# >> 如何让计算机更快?

## > 并行的思路是否有局限性?

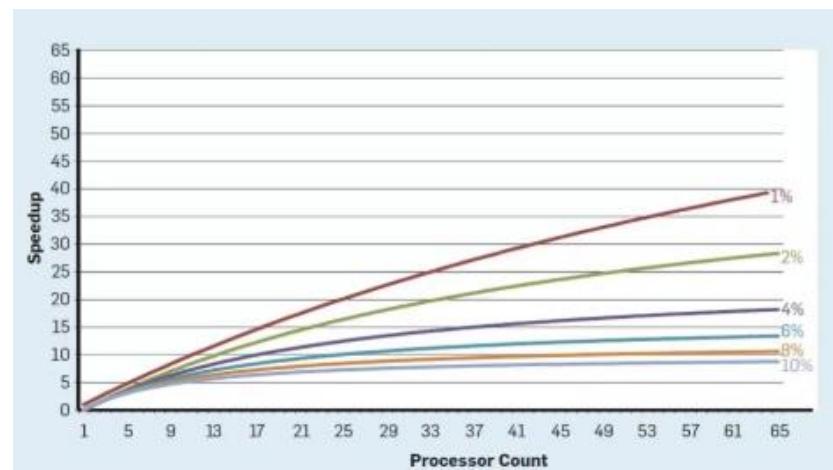
例：50%的程序不能并行执行，这时用64核并行，会加速多少倍？

$$\text{全局加速比} = 1 / (0.5 + 0.5/64) = 1.97$$

- 对于50%部分可以并行的程序，64核处理器只加速不到2倍！  
花费了64倍的功耗！



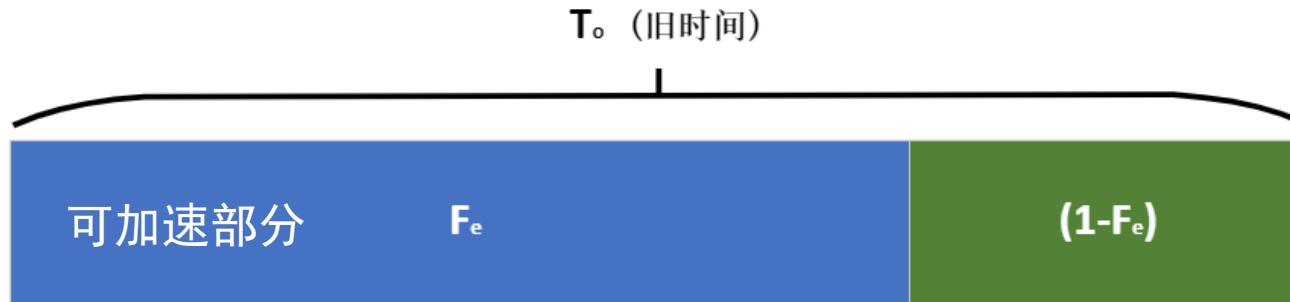
多核处理器



# » Amdahl定律

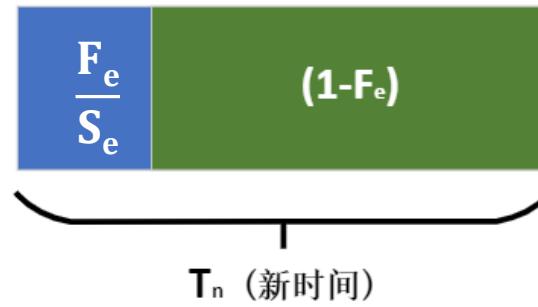
➤ 系统加速比定义：

$$S_n = \frac{\text{加速后的速度}}{\text{原始速度}} = \frac{\text{未加速的耗时}}{\text{加速后的耗时}}$$



$S_e$  – 加速倍数

$F_e$  – 可加速部分占总时间百分比



# » Amdahl定律

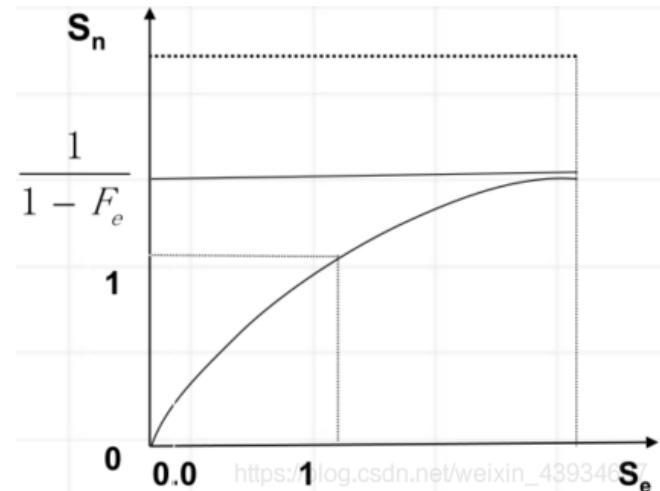
因此，根据加速比定义有：

$$S_n = \frac{T_o}{T_n} = \frac{1}{(1-F_e) + \frac{F_e}{S_e}}$$

具体来说， $F_e$ 不变，随着 $S_e$ 增大， $S_n$ 增速越来越慢，且收敛到极限  $\frac{1}{1-F_e}$

这就是Amdahl定律的**性能递减规则**：

- 若仅对计算机一部分做性能提速，则改进越多，所得到的总性能提升越有限

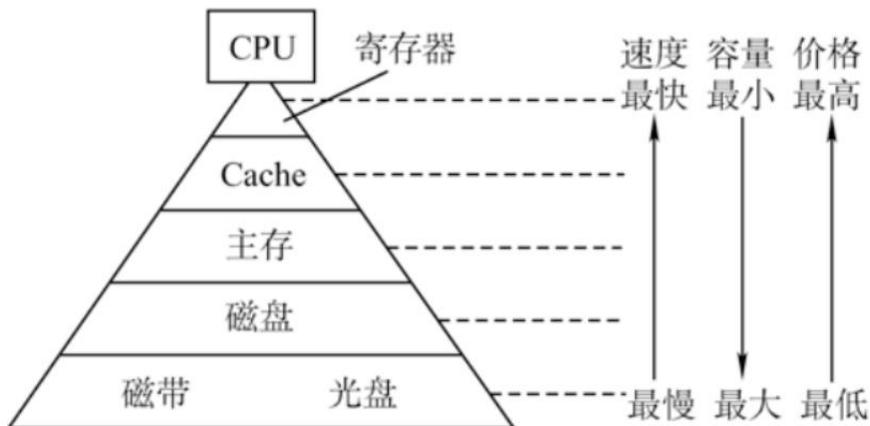


因此，要想办法增加 $F_e$ 的比例，即加速经常发生的事件

# >> 如何让计算机更快?

## ➤ 加速经常发生的事件-示例

### ➤ 存储系统加速



存储器	硬件介质	单位成本 ( 美元/MB )	随机访问延时
L1 Cache	SRAM	7	1ns
L2 Cache	SRAM	7	4ns
Memory	DRAM	0.015	100ns
Disk	SSD ( NAND )	0.0004	150μs
Disk	HDD	0.00004	10ms

## 分级存储体系：

相对不容易被访问的内容，放入便宜、容量大、速度慢的存储

相对容易被访问的内容，放在快速、昂贵的存储

# >> 如何让计算机更快?

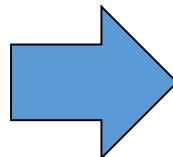
➤ 加速经常发生的事件-示例

➤ CISC，复杂指令集系统

多媒体功能常用，涉及大量浮点计算



CPU (80286)



奔腾芯片：增加浮点指令

减少了一个任务需要的指令数

# >> 如何让计算机更快?

- 复杂指令级的代价!
  - 越来越复杂的电路
  - 指令的时钟周期很难对齐
  - 流水线难管理
- RISC, 精简指令级系统
  - 只保留最核心的指令
  - 全部资源优化保留的指令速度



两种对立统一的优化思路, 从Amdahl定律看, RISC是更极致的增加Fe (加速事件占比)

# »» 如何让计算机更快?

## ➤ 进一步的认识与发现

- 各领域计算模式差异化，采用相同结构通用处理器进行计算，效率低下。
- 大量指令很少使用，晶体管资源大量浪费。



David A. Patterson

➤ 新思路：领域特定结构（DSA-Domain Specific Architecture），针对不同领域的计算模式，设计专用的硬件加速器或计算机体系结构。

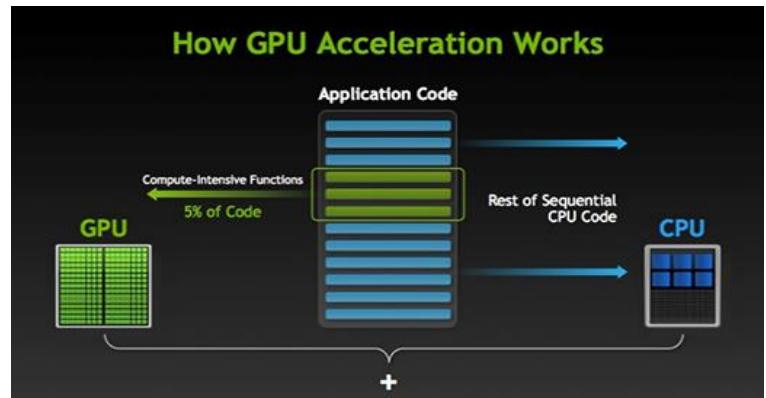
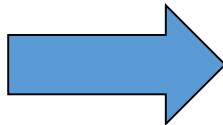
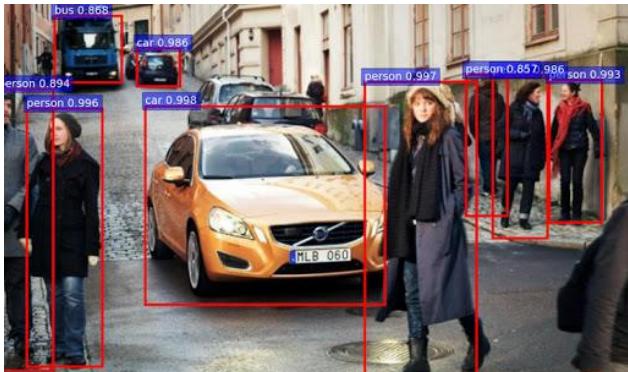
# >> 如何让计算机更快?

## ➤ DSA结构实例-GPU的兴起



相比于CPU

- GPU 拥有数以千计的计算核心，可高效地处理并行任务；
- GPU牺牲了逻辑处理能力，得到更强的大规模计算能力。



计算密集型任务分配给GPU运算

# >> 如何让计算机更快?

## ➤ DSA结构实例-GPU的兴起

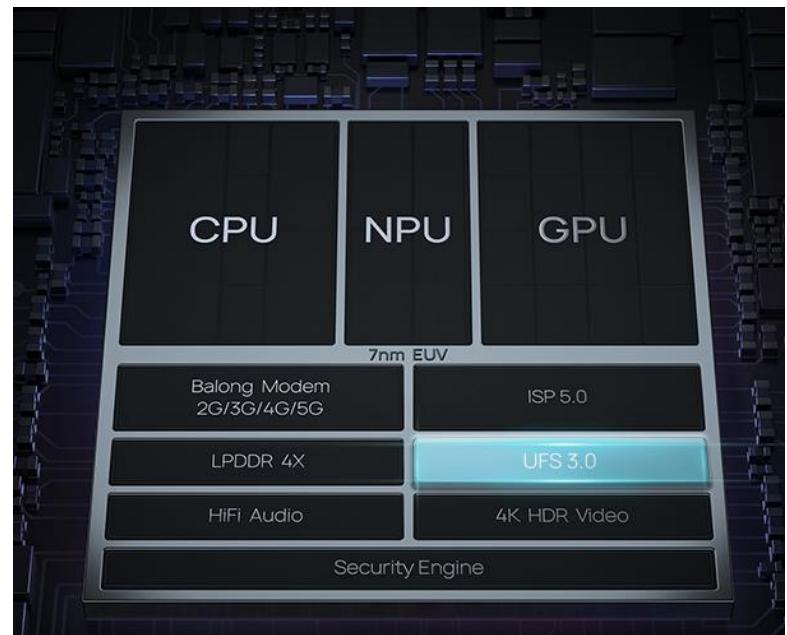
采用GPU的超级计算机-天河一号

中国研制成功每秒运算逾千万亿次超级计算机

「天河一号」	全系统峰值性能	1206万亿次/秒
	Linpack实测性能	563.1万亿次/秒
	共享存储总容量	1PB
	全系统包含通用处理器(CPU)	6144个
	全系统包含加速处理器(GPU)	5120个
	互连通信网络的单根线传输速率	10Gbps
	目前投资	6亿人民币
	使用寿命预计	10年
	全系统运行情况下耗电	1280度/小时



手机芯片麒麟990

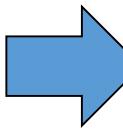


# >> 如何让计算机更快?

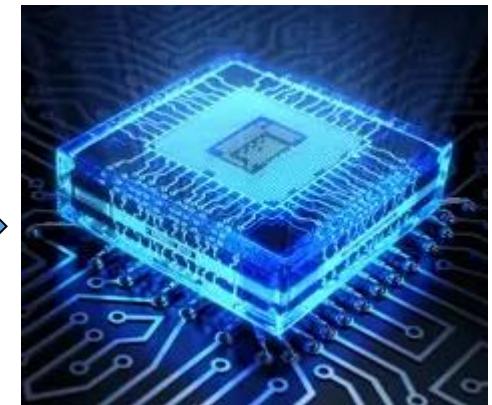
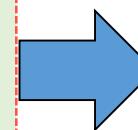
## ➤ DSA结构实例-CPU+FPGA可重构架构



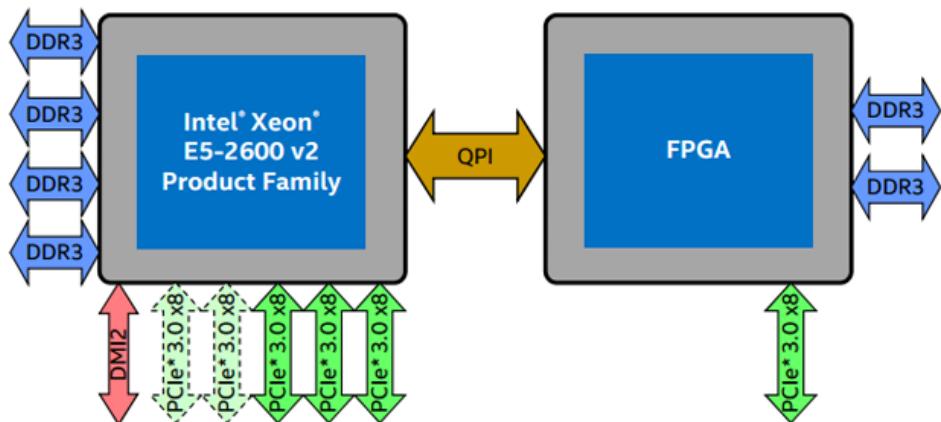
通用CPU



通用CPU速度慢，  
无法满足特定计  
算需求



FPGA加速 (Field  
Programmable Gate  
Array)



CPU+FPGA架构

# >> 如何让计算机更快?

## ➤ DSA结构实例-CPU+FPGA可重构架构

Intel公司收购Altera公司  
从分离到集成，构建可重构平台



**ALTERA AND INTEL  
HAVE JOINED FORCES**

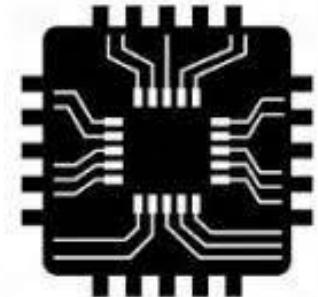
Together, we will achieve more success for our customers and help accelerate a smart and connected world.

[Read about our commitment](#)

Xilinx公司收购了AutoESL

**EF-AUTOESL-NL**

 XILINX

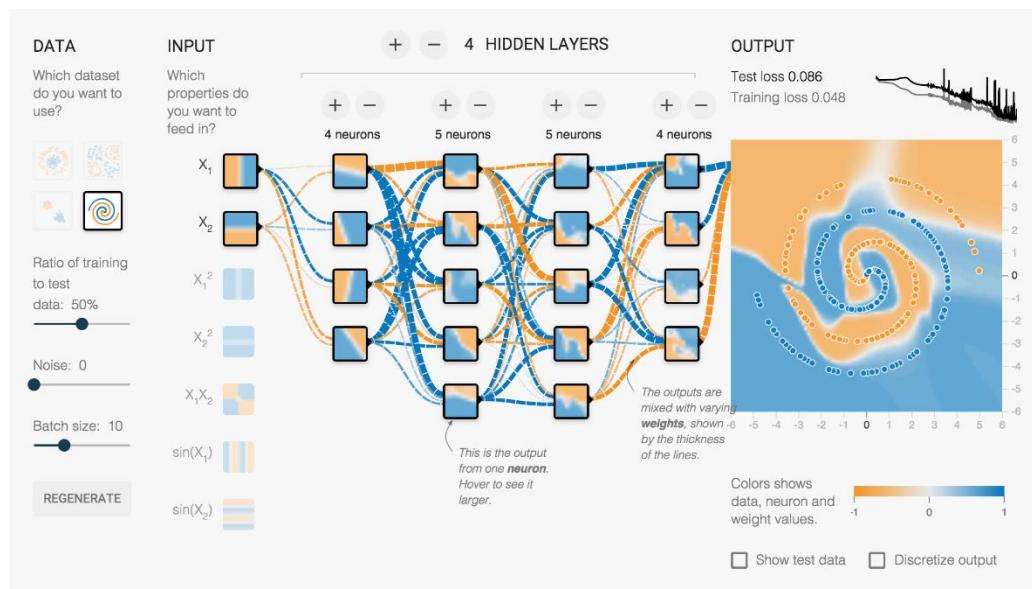
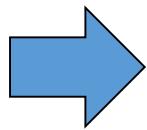
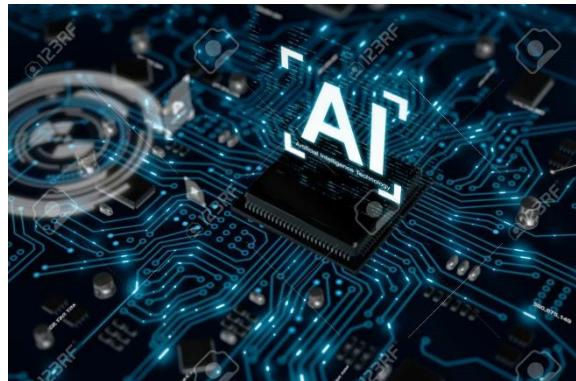


 耐智电子

# »» 如何让计算机更快?

## ➤ DSA结构实例-CPU+AI加速器

AI加速器是一种针对深度学习算法的硬件处理器



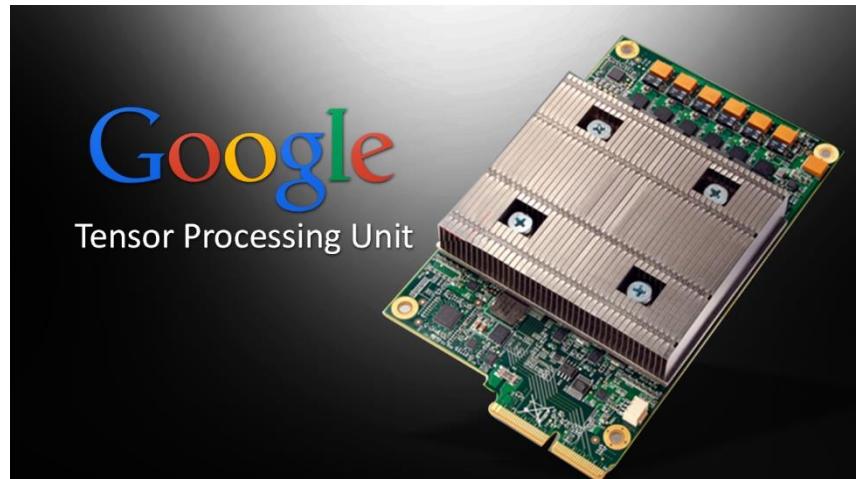
# >> 如何让计算机更快?

## ➤ DSA结构实例-CPU+AI加速器

中科院寒武纪芯片



GOOGLE的TPU处理器



# »» 阅读材料

---

- <https://www.starduster.me/2020/11/05/modern-microprocessors-a-90-minute-guide/>

# »» 作业

---

- 这堂课的内容对你将来写程序有什么启示？为了写出更快的程序，你会考虑哪些内容？
- 什么是ISA？为什么ISA与硬件功能密切相关？
- 阅读c语言的fork()函数，尝试写出一个并行程序。  
输入为100000个数字，让进程1对前50000个数排序，  
进程2对后50000个数排序，然后对整体100000个数  
字按顺序输出。



西安交通大学  
XI'AN JIAOTONG UNIVERSITY

# 第五讲 (part 2)： 计算机系统结构概述

师斌

School of Computer Science & Technology



# >> Related courses

## Computer Hardware Design

- Computer Organization
- Digital Logic Design
- Circuit
- Computer Architecture
- .....

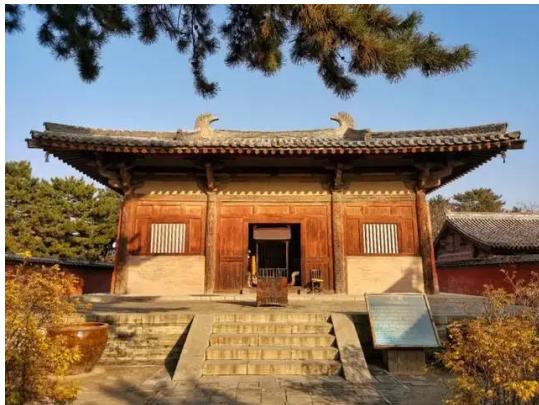
## Instruction Set Design

- Assembly Language
- Compile
- Computer Architecture
- .....

Very many people are concerned with computer function; Many people design computer components; Few design instruction sets!  
Very few people design computers!

# » Computer Architecture

- 什么是计算机系统结构?



中国砖木建筑



欧洲石材建筑



现代钢结构玻璃建筑

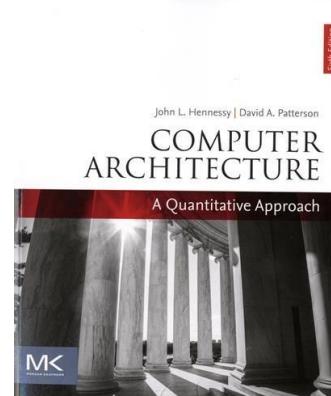
- 建筑师用不同的材料设计建筑；计算机架构师用晶体管组成的部件设计计算机

# »» 计算机系统结构- 定义

“computer architecture covers three aspects of computer design:

- instruction set architecture,
- computer organization and
- computer hardware.”

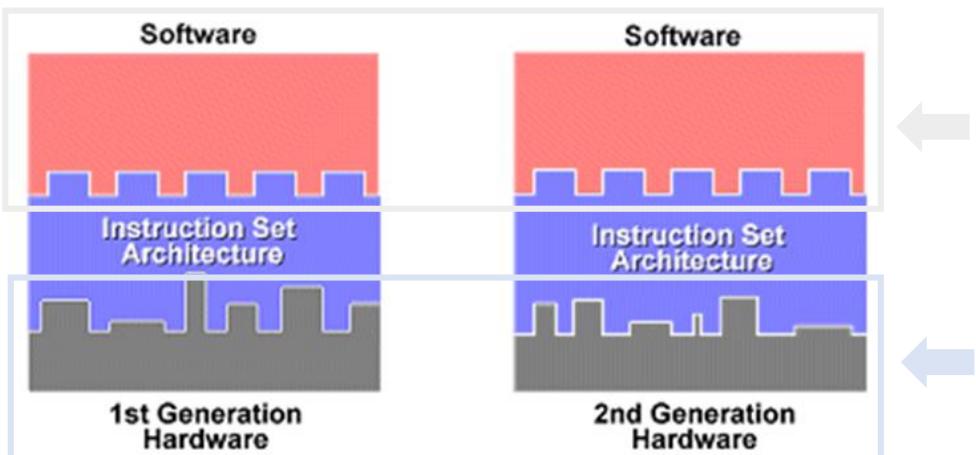
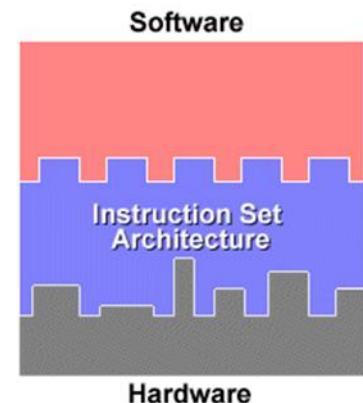
——John L. Hennessy & David A. Patterson, 1990



因计算机体系结构方面做出的突出贡献，获得2017年图灵奖

# » Instruction Set Architecture (ISA)

- ISA is defined as **group of commands** and operations used by the software to communicate with the hardware. It acts as an **interface** between the hardware and the software, specifying a computer “What to do?”
- 可以认为指令集是一个计算机的硬件系统所提供的全部功能



The programs written for a particular IS could run on any machine that implemented that IS.

Manufacturers could innovate and fine-tune that hardware for performance without worrying about breaking the existing software base.

# » Computer Organization

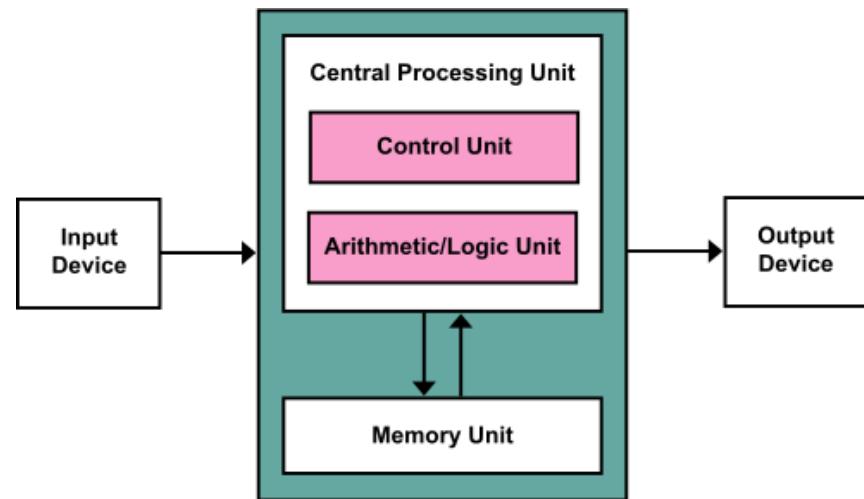
- Computer organization refers to the way in which the hardware components of a computer system are arranged and interconnected. It implements the provided computer architecture and covers the "How to do?" part.



计算机之父

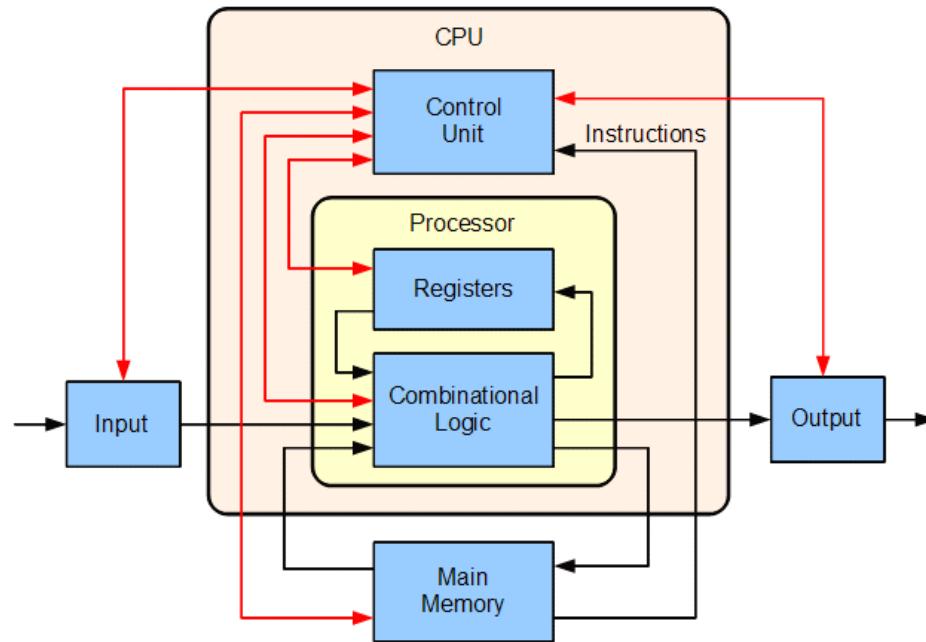
约翰·冯·诺依曼

John von Neumann



Von Neumann architecture scheme

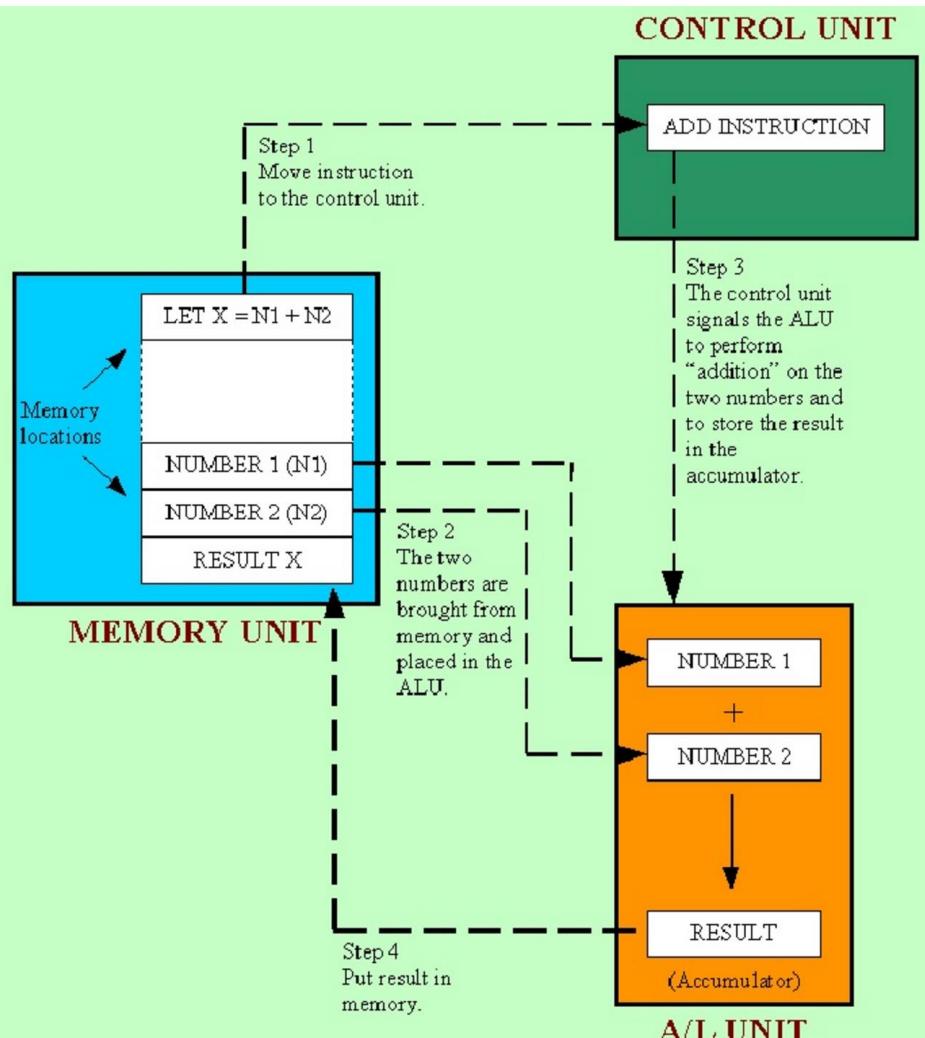
# » Computer Organization



CPU里有哪些主要部件呢？

- **Arithmetic/Logic Unit (ALU):** 执行算术和逻辑运算;
- **Registers:** 向 ALU 提供操作数并存储 ALU 运算的结果;
- **Control Unit (CU):** 从内存中获取指令并通过指导 ALU、寄存器和其他组件的协调操作来“执行”它们。

# » Computer Organization



CPU 如何工作?

步骤 1: **CU** 从主存 (物理内存, RAM) 或寄存器中获取指令。

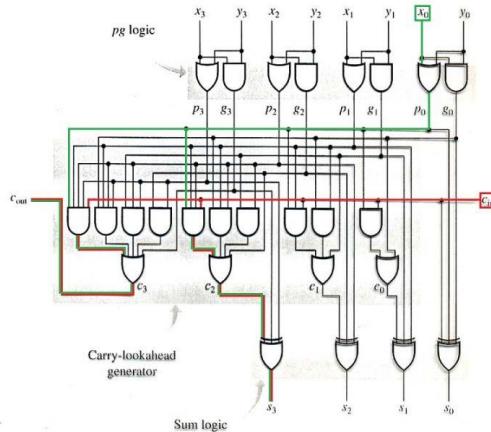
第 2 步: **CU** 确定指令的含义, 并将必要的数据从 **主存** 或寄存器移动到 **ALU**。

第 3 步: **ALU** 对数据执行实际操作。

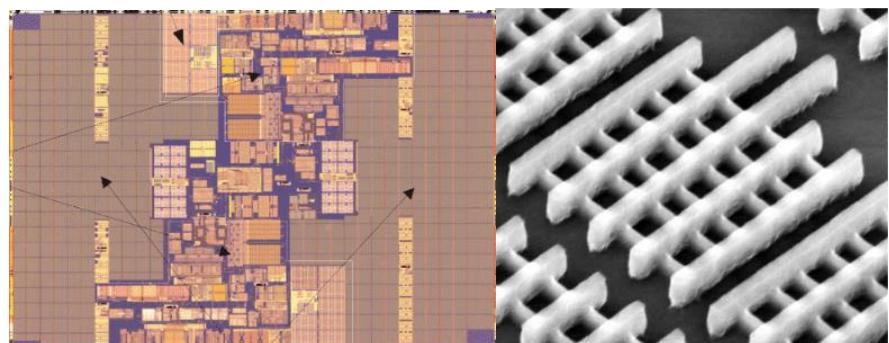
第 4 步: 运算结果存储在 **主存** 或寄存器中。

# » Computer hardware

- Computer hardware refers to the specifics of a machine, included the detailed logic design and the packaging technology of the machine.



逻辑设计-四位加法器

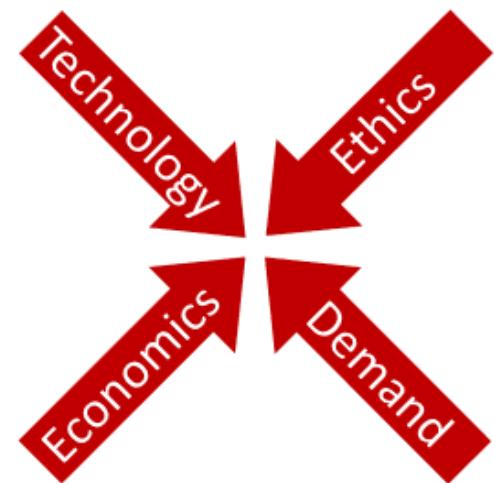


芯片电路

Computer organization and computer hardware are two components of the implementation of a machine

# »» 计算机系统结构的任务

- 目标：设计计算机，在满足功能要求的条件下，优化成本、功耗和性能目标。
- 所以说……
  - 计算机系统结构是一门工程科学
  - 需要学习如何在满足各类约束条件下提出解决方案
- 最重要的目标是？
  - 性能！快！



Don't memorize instances; understand why it is that way